

Éthique des données

Master 2 TAL

Semestre 2

Pourquoi une éthique des données en NLP ?

- Les modèles NLP modernes reposent sur des quantités massives de données textuelles issues du web et de sources hétérogènes.
- Ces données contiennent des biais sociaux, culturels et historiques qui sont appris par les modèles.
- L'IA n'est donc pas neutre : elle reproduit et amplifie les structures présentes dans les données.
- L'éthique devient ainsi une contrainte fondamentale dans la conception et l'usage des systèmes NLP.

Spécificités des données textuelles

- Le texte encode des informations implicites sur les opinions, les normes sociales et les représentations culturelles.
- Le langage est ambigu et dépend fortement du contexte, ce qui rend les interprétations incertaines.
- Les ressources linguistiques sont très inégalement réparties, avec une domination de l'anglais.
- Une grande partie des données est collectée automatiquement, souvent sans contrôle explicite.

Quels sont les principaux risques ?

- Les modèles peuvent produire des décisions biaisées ou discriminatoires envers certains groupes.
- Les données utilisées peuvent contenir des informations personnelles sensibles, exposant les individus.
- Le fonctionnement interne des modèles est souvent difficile à interpréter.
- Les systèmes NLP peuvent être utilisés à des fins de manipulation ou de désinformation.

D'où viennent les biais ?

- Les biais historiques présents dans les textes sont directement appris par les modèles.
- Les datasets sont souvent non représentatifs de la diversité réelle des populations.
- Les annotations humaines introduisent une subjectivité difficile à contrôler.
- Les objectifs d'optimisation favorisent la performance globale plutôt que l'équité.

Exemples concrets en NLP

- Les word embeddings associent fréquemment certains métiers à un genre spécifique.
- Les modèles génératifs peuvent produire des contenus stéréotypés ou offensants.
- Les classifieurs de toxicité pénalisent parfois certains dialectes ou styles linguistiques.
- Les systèmes de traduction automatique introduisent des biais de genre.

Vie privée et données textuelles

- Les textes peuvent contenir des données personnelles explicites ou permettre des inférences sensibles.
- Même anonymisées, certaines données peuvent permettre une ré-identification.
- Les données sensibles incluent plusieurs sujet comme la santé ou les opinions politiques.
- Il existe une tension forte entre performance des modèles et protection de la vie privée.

Le RGPD : principes fondamentaux

- Le RGPD impose que les données soient collectées pour une finalité précise et légitime.
- Le consentement des utilisateurs doit être explicite et informé.
- Le principe de minimisation impose de ne collecter que les données strictement nécessaires.
- Les individus disposent d'un droit d'accès, de rectification et de suppression de leurs données.

Autres régulations et limites

- D'autres cadres comme le CCPA ou l'AI Act complètent la régulation des données et de l'IA.
- Ces régulations introduisent des obligations de transparence et de gestion des risques.
- Toutefois, elles peinent à suivre la rapidité des évolutions technologiques.
- Les modèles de grande taille posent des défis nouveaux en termes de responsabilité.

Transparence et documentation

- Les Data Statements permettent de documenter précisément la composition des datasets.
- Les Model Cards décrivent les usages, limites et performances des modèles.
- La traçabilité des données est essentielle pour comprendre les comportements des systèmes.
- Cependant, la transparence ne garantit pas une compréhension complète des modèles.

Équité et fairness

- Il existe plusieurs définitions de l'équité, souvent incompatibles entre elles.
- Les métriques de fairness dépendent fortement du contexte d'application.
- Améliorer l'équité peut parfois réduire la performance globale du modèle.
- L'équité doit être pensée comme un compromis plutôt qu'un objectif absolu.

Réduction des biais

- Les biais peuvent être atténués en équilibrant les données d'entraînement.
- Des contraintes peuvent être ajoutées directement dans le processus d'apprentissage.
- Des ajustements peuvent être faits après l'entraînement pour corriger certaines dérives.
- Toutefois, aucune méthode ne permet de supprimer totalement les biais.

Utilisation des modèles publics : risques

- L'utilisation d'API implique l'envoi de données à un fournisseur externe.
- Ces données peuvent être stockées, analysées ou réutilisées sans contrôle total.
- Cela pose des problèmes de conformité avec le RGPD, notamment pour les données sensibles.
- Il existe un risque de fuite ou d'exposition indirecte des informations.

Bonnes pratiques : modèles locaux

- Il est recommandé d'utiliser des modèles open-source exécutés en local.
- Le traitement offline permet de garder un contrôle total sur les données.
- Les données sensibles ne doivent jamais être envoyées via des API externes.
- Les modèles doivent être audités avant leur utilisation en production.

Responsabilité et déploiement

- Les modèles doivent être surveillés en continu après leur déploiement.
- Des dérives peuvent apparaître avec le temps ou selon les usages.
- Le feedback utilisateur est essentiel pour détecter des problèmes.
- La responsabilité est partagée entre chercheurs, ingénieurs et organisations.

Conclusion

- Les modèles NLP ne sont jamais neutres et reflètent leurs données d'entraînement.
- L'éthique des données est une dimension centrale du développement en IA.
- Une approche interdisciplinaire est nécessaire pour traiter ces enjeux.
- Chaque praticien doit définir les limites acceptables de ses systèmes.

Ressources sur l'éthique des données en IA

- ❶ Khan, A.A., Badshah, S., Liang, P., et al. (2021). *Ethics of AI: A Systematic Literature Review of Principles and Challenges*. arXiv:2109.07906.
<https://arxiv.org/abs/2109.07906>
- ❷ Hagendorff, T. (2024). *Mapping the Ethics of Generative AI: A Comprehensive Scoping Review*. arXiv:2402.08323.
<https://arxiv.org/abs/2402.08323>
- ❸ Zhang, J., Zhang, Z.-m. (2023). *Ethics and governance of trustworthy medical artificial intelligence*. BMC Med Inform Decis Mak 23, 123.
<https://bmcmmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-023-02103-9>