

# TP6 et Projet – Chatbot administratif

## 1. Objectifs pédagogiques

Ce projet vise à analyser de manière critique deux stratégies d'adaptation des LLM à un domaine spécialisé (administration universitaire) :

- Comprendre les limites du prompting sur petit corpus.
- Évaluer l'efficacité du fine-tuning supervisé en faible volume de données.
- Concevoir et implémenter un système RAG complet.
- Comparer expérimentalement plusieurs modèles de taille comparable.
- Mettre en place une évaluation rigoureuse combinant métriques automatiques et évaluation humaine.
- Produire une analyse argumentée fondée sur des résultats mesurés.

## 2. Contexte

Un premier travail a été réalisé sur un corpus de 47 questions administratives. Les expérimentations par prompting ont montré :

- Manque de précision
- Hallucinations fréquentes
- Instabilité des réponses
- Difficulté à contrôler le modèle

Le corpus est trop petit pour obtenir des performances robustes uniquement via prompting.

Nous allons comparer deux approches :

1. Fine-tuning supervisé
2. Retrieval-Augmented Generation (RAG)

Les modèles à comparer :

- Ministral-14B (version base pour fine-tuning, version instruct pour RAG), développé par Mistral AI
- Llama 3 8B (version base pour fine-tuning, version instruct pour RAG), développé par Meta AI

# 3. TP6 – Fine-tuning (séance actuelle)

## 3.1 Objectif

Mettre en place un fine-tuning supervisé sur le corpus des 47 questions afin d'évaluer si une adaptation paramétrique améliore :

- la précision factuelle,
- la stabilité,
- la réduction des hallucinations.

## 3.2 Préparation des données

1. Nettoyage du corpus.
2. Reformattage au format instruction tuning :
  - instruction (question)
  - réponse (réponse de référence)
3. Séparation :
  - 80 % train
  - 20 % test

Le jeu de test doit rester strictement séparé pour l'évaluation.

## 3.3 Protocole expérimental

Vous devez :

- Fine-tuner Ministral-14B (version non instruct).
- Fine-tuner Llama 3 8B (version base).

Le fine-tuning complet n'est pas requis. Une approche paramétriquement efficace est recommandée (LoRA, QLoRA ou équivalent).

Comparer systématiquement :

- Modèle de base
- Modèle fine-tuné

## 3.4 Évaluation automatique (fine-tuning)

Les modèles doivent être évalués sur le jeu de test à l'aide de :

### 1. BERTScore

Mesure de similarité sémantique avec la réponse de référence.

## 2. MNLI (entailment)

Vérifier si la réponse générée :

- implique la réponse de référence,
- la contredit,
- ou est neutre.

## 3. LLM as a Judge

Un LLM doit évaluer :

- exactitude factuelle,
- pertinence,
- hallucinations,
- clarté.

Les résultats doivent être présentés de manière quantitative et comparative.

# 4. Travail à réaliser pendant les 3 semaines (RAG)

Pendant l'interruption des cours, vous devez concevoir un système RAG complet.

## 4.1 Construction de la base documentaire

Vous devez constituer une base documentaire réelle concernant l'administration de l'INALCO :

- Pages officielles du site
- FAQ
- Règlements
- Calendrier universitaire
- Documents institutionnels
- Pages descriptives des formations

Étapes attendues :

1. Collecte
2. Nettoyage
3. Segmentation en chunks cohérents
4. Calcul d'embeddings
5. Indexation dans une base vectorielle (FAISS, Chroma, etc.)

Les 47 questions servent uniquement de jeu de test.

## 4.2 Implémentation du pipeline RAG

Le pipeline doit comporter :

1. Requête utilisateur
2. Retrieval top-k
3. Injection contrôlée du contexte
4. Génération

Modèles à tester :

- Ministral-14B Instruct
- Llama 3 8B Instruct

## 4.3 Évaluation automatique (RAG)

Même protocole que pour le fine-tuning :

- BERTScore
- MNLI
- LLM as a Judge

Comparer :

- Modèle seul
- Fine-tuning
- RAG

Une comparaison expérimentale structurée est attendue.

# 5. Évaluation humaine

Une évaluation qualitative doit être réalisée sur un sous-ensemble représentatif.

Critères :

1. Exactitude factuelle
2. Pertinence
3. Absence d'hallucination
4. Clarté
5. Utilité pour un étudiant réel
6. Adéquation au ton institutionnel

Notation recommandée : échelle 1–5.

Vous devez analyser les divergences entre évaluation automatique et humaine.

## 6. Rapport final

Longueur attendue : 8–12 pages.

Le rapport doit contenir :

- Description des données
- Description méthodologique (fine-tuning et RAG)
- Paramètres expérimentaux
- Résultats automatiques
- Résultats de l'évaluation humaine
- Analyse comparative
- Discussion critique
- Conclusion argumentée

La conclusion doit répondre explicitement :

- Le fine-tuning sur petit corpus est-il pertinent ?
- Le RAG réduit-il mieux les hallucinations ?
- Quel modèle est le plus stable ?
- Quelle solution recommanderiez-vous pour un déploiement réel à l'INALCO ?

## 7. Deadlines

- **Rendu TP6 (Fine-tuning) :**

Ce week-end.

À rendre :

- Code complet
- Scripts d'entraînement
- Scripts d'évaluation
- Résultats automatiques
- **31 mars :**
  - Présentation orale des projets
  - Rendu du rapport final
  - Code complet (fine-tuning + RAG + évaluation)